

INSEDS

Institut Supérieur de Statistique, d'Économétrie et de Data Science

MINI-PROJET N°2

ANALYSE DES DONNÉES MULTIDIMENSIONNELLES

Segmentation de la Clientèle d'un Centre Commercial

ENCADREUR : **AKPOSSO** Didier Martial

Année académique : 2025-2026

MASTER 2 : **STATISTIQUE – ECONOMETRIE – DATA SCIENCE**

ENCADRE : **YAO Kouakou Jean Martinien**

Année académique 2025-2026

SOMMAIRE

1. INTRODUCTION GÉNÉRALE.....	3
2. DONNÉES ET MÉTHODOLOGIE	4
3. RÉSULTATS	5
4. ANALYSE EN COMPOSANTES PRINCIPALES (ACP).....	7
5. ANALYSE DES CORRESPONDANCES MULTIPLES (ACM)	11
6. CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH).....	14
7. CLUSTERING PAR K-MEANS.....	15
8. DISCUSSION.....	17
9. CONCLUSION ET RECOMMANDATIONS	18
ANNEXE — CODE SOURCE COMPLET	19

1. INTRODUCTION GÉNÉRALE

Dans un contexte de concurrence accrue entre les acteurs du commerce de détail, les entreprises cherchent à mieux comprendre le comportement de leurs clients afin d'adapter leurs stratégies marketing, commerciales et financières. La capacité à identifier des segments homogènes de consommateurs constitue un avantage compétitif déterminant dans un environnement où l'offre est pléthorique et les attentes des consommateurs de plus en plus différenciées.

La segmentation client repose sur l'idée que tous les clients ne se ressemblent pas et que des groupes distincts peuvent être traités de manière différenciée pour maximiser la satisfaction, la fidélisation et la rentabilité. Elle permet notamment de personnaliser les offres, d'optimiser l'allocation des budgets promotionnels et de développer des programmes de fidélité adaptés à chaque profil.

Ce mini-projet mobilise un jeu de données enrichi de 200 clients d'un centre commercial, comprenant des variables quantitatives et qualitatives. L'objectif est de mettre en œuvre les principales techniques d'analyse multivariée :

- Analyse en Composantes Principales (ACP) pour synthétiser les variables quantitatives
- Analyse des Correspondances Multiples (ACM) pour explorer les relations entre variables qualitatives
- Classification Ascendante Hiérarchique (CAH) pour identifier la structure naturelle des groupes
- Clustering par K-means pour une segmentation opérationnelle et actionnable

1.1 Problématique

Comment segmenter efficacement les 200 clients d'un centre commercial à partir de leurs caractéristiques démographiques, financières et comportementales afin de dégager des profils types permettant d'orienter de manière ciblée la stratégie marketing de l'enseigne ?

1.2 Objectifs spécifiques

- Appliquer l'ACP pour analyser les variables quantitatives et identifier les principaux axes de variation
- Utiliser l'ACM pour étudier les associations entre les variables qualitatives
- Construire une CAH afin d'explorer la structure hiérarchique des clients
- Mettre en œuvre un K-means pour une segmentation opérationnelle
- Interpréter les classes obtenues d'un point de vue marketing et business

2. DONNÉES ET MÉTHODOLOGIE

2.1 Présentation du jeu de données

Le jeu de données est la version enrichie du dataset « Mall Customers ». Il comprend 200 observations et 9 variables d'analyse réparties en deux catégories.

Variables quantitatives (6 variables)

Variable	Description	Statistiques clés
Âge	Âge du client en années	Moy=38,85 Min=18 Max=70
Revenu Annuel	Revenu annuel estimé (en k\$)	Moy=60,56 Min=15 Max=137
Score Dépenses	Indice comportemental de dépenses (1–100)	Moy=50,20 Min=1 Max=99
Épargne Estimée	Montant épargné estimé annuel (en k\$)	Moy=40,25 Min=6,46 Max=120,56
Score de Crédit	Score de solvabilité bancaire	Moy=743,68 Min=300 Max=850
Années de Fidélité	Ancienneté comme client (en années)	Moy=5,93 Min=2 Max=9

Variables qualitatives (3 variables)

Variable	Modalités	Effectifs observés
Sexe	Femme / Homme	Femme: 112 (56 %) Homme: 88 (44 %)
Groupe d'Âge	18-25 / 26-35 / 36-50 / 51-65 / 65+	18-25:38 26-35:60 36-50:62 51-65:28 65+:12
Catégorie Préférée	Budget / Electronics / Fashion / Luxury	Budget:27 Electronics:78 Fashion:41 Luxury:54

2.2 Plan d'analyse

- Étape 1 – Importation et exploration initiale des données
- Étape 2 – Pré-traitement : vérification des valeurs manquantes et aberrantes, standardisation
- Étape 3 – Interprétation des inerties (valeurs propres, graphe de l'éboullis)
- Étape 4 – Analyse du graphe des individus et résumés numériques
- Étape 5 – Analyse des variables (cercle de corrélation ACP, carte des modalités ACM)
- Étape 6 – Conclusion synthétique par méthode

La CAH (Ward) et le K-means sont appliqués sur l'espace des variables standardisées pour la segmentation opérationnelle.

3. RÉSULTATS

3.1 Pré-traitement et Statistiques Descriptives

3.1.1 Pré-traitement des données

- Valeurs manquantes : 4 valeurs manquantes détectées sur la variable « Groupe d'Âge » (clients n° 34, 66, 92 et 115, tous âgés de 18 ans). Ces valeurs ont été traitées par imputation KNN (K-Nearest Neighbors Imputation, $k = 5$, pondération par distance) : le groupe d'âge de chaque observation manquante est estimé comme la moyenne pondérée des groupes d'âge de ses 5 voisins les plus proches dans l'espace des variables « Âge », « Revenu annuel » et « Score de dépenses ». Le groupe d'âge est encodé de manière ordinale (1 = 18-25, 2 = 26-35, 3 = 36-50, 4 = 51-65, 5 = 65+) avant imputation, puis la valeur numérique obtenue est arrondie et décodée. Résultat : les 4 observations se voient attribuer le groupe « 18-25 » (score KNN brut : 1,000–1,137), ce qui est cohérent avec leur âge réel de 18 ans. Aucune autre valeur manquante présente dans le jeu de données.
- Valeurs aberrantes : le score de crédit présente un plancher à 300 pour plusieurs clients. Ces valeurs sont conservées car elles représentent un profil réel de faible solvabilité bancaire.
- Standardisation : les 6 variables quantitatives ont été centrées-réduites ($\mu=0$, $\sigma=1$) avant l'ACP et le K-means pour rendre les échelles comparables.

3.1.2 Statistiques descriptives des variables quantitatives

Variable	Moy.	Écart-type	Min	Q1	Médiane	Q3	Max
Âge	38,85	13,97	18	28,75	36,00	49,00	70
Revenu (k\$)	60,56	26,26	15	41,50	61,50	78,00	137
Score Dépenses	50,20	25,82	1	34,75	50,00	73,00	99
Épargne (k\$)	40,25	21,33	6,46	28,80	36,41	44,97	120,56
Score Crédit	743,68	155,18	300	697,00	833,00	850,00	850
Années Fidélité	5,93	1,57	2	5,00	6,00	7,00	9

Commentaires : Le revenu annuel présente la plus grande dispersion (CV = 43 %). Le score de dépenses est uniformément distribué (médiane $\approx$ moyenne = 50). Le score de crédit est asymétrique à gauche avec une majorité de clients au-dessus de 697 (bon profil), mais un sous-groupe à 300 (crédit minimal).

3.2 Matrice de Corrélation

La matrice de corrélation (coefficients de Pearson) révèle la structure des liaisons linéaires du jeu de données.

Variable	Âge	Revenu	Sc.Dép.	Épargne	Sc.Crédit	An.Fid.
Âge	1,000	-0,012	-0,327	0,126	0,237	0,606
Revenu	-0,012	1,000	0,010	0,814	0,749	-0,020
Sc.Dép.	-0,327	0,010	1,000	-0,516	-0,296	0,533
Épargne	0,126	0,814	-0,516	1,000	0,689	-0,325
Sc.Crédit	0,237	0,749	-0,296	0,689	1,000	-0,057
An.Fid.	0,606	-0,020	0,533	-0,325	-0,057	1,000

Cellules en bleu : corrélations fortes $|r| > 0,29$.

- Revenu ↔ Épargne : $r = 0,814$ — l'épargne croît très fortement avec le revenu
- Revenu ↔ Score Crédit : $r = 0,749$ — les clients aisés ont un meilleur profil de solvabilité
- Épargne ↔ Score Crédit : $r = 0,689$
- Âge ↔ Années Fidélité : $r = 0,606$ — les clients âgés sont aussi les plus fidèles
- Score Dépenses ↔ Épargne : $r = -0,516$ — les gros dépensiers épargnent peu
- Score Dépenses ↔ Années Fidélité : $r = 0,533$ — les clients fidèles sont davantage dépensiers
- Score Dépenses ↔ Âge : $r = -0,327$
- — les jeunes tendent à plus dépenser

Synthèse : Deux blocs émergent : (1) un bloc « richesse » regroupant Revenu, Épargne et Score de Crédit, et (2) un bloc « comportement-fidélité » regroupant Score de Dépenses, Années de Fidélité et Âge. Cette structure préfigure exactement les deux premiers axes de l'ACP.

4. ANALYSE EN COMPOSANTES PRINCIPALES (ACP)

L'ACP est appliquée sur la matrice des corrélations (variables centrées-réduites). Elle résume l'information des 6 variables quantitatives en un petit nombre de composantes principales non corrélées.

4.1 Étape 3 — Interprétation des inerties

Tableau des valeurs propres

Dim.	Valeur propre (λ)	% Inertie	% Cumulé	Kaiser	Décision
F1	2,7564	45,94 %	45,94 %	✓	Retenue
F2	1,6755	27,92 %	73,86 %	✓	Retenue
F3	1,2695	21,16 %	95,02 %	✓	Retenue
F4	0,2957	4,93 %	99,95 %	✗	Non retenue
F5	0,0208	0,35 %	100,00 %	✗	Non retenue
F6	0,0124	0,21 %	100,00 %	✗	Non retenue

Graphique de l'éboulis (Diagramme des valeurs propres)




Figure 1 — Graphique des valeurs propres (Scree plot). Barres : valeurs propres avec % d'inertie. Courbe orange : inertie cumulée. Ligne rouge pointillée : seuil de Kaiser ($\lambda=1$).

Interprétation : Selon le critère de Kaiser ($\lambda > 1$), 3 axes sont retenus : F1 ($\lambda=2,756$, 45,94 %), F2 ($\lambda=1,676$, 27,92 %) et F3 ($\lambda=1,270$, 21,16 %). Ces 3 composantes expliquent 95,02 % de la variance totale. Le plan F1×F2 capture à lui seul 73,86 % de l'inertie, offrant une représentation

bidimensionnelle très fidèle de la structure des données. Le diagramme de l'éboullis confirme un coude net après F3.

4.2 Étape 4 — Carte Factorielle des Individus (Plan F1×F2)

Le graphique suivant représente la projection des 200 clients sur le plan factoriel F1×F2. Chaque point est coloré selon la catégorie de consommation préférée du client, et les marqueurs changent selon la catégorie (cercle, carré, triangle, losange).




Figure 2 — Carte factorielle des individus (ACP, plan F1×F2, 73,86 % de variance). Couleurs et formes par catégorie préférée.

Lecture de la carte des individus : L'axe horizontal F1 (45,94 %) oppose les clients à fort revenu et forte épargne (droite, +F1) aux clients modestes (gauche, -F1). L'axe vertical F2 (27,92 %) oppose les clients âgés et fidèles (haut, +F2) aux clients jeunes et peu fidèles (bas, -F2). Quatre zones se dégagent :

- Quadrant (+F1, +F2) — Riches & Fidèles : clients seniors à fort pouvoir financier et longue fidélité
- Quadrant (+F1, -F2) — Riches & Jeunes : clients jeunes à fort revenu, peu fidèles — segment premium potentiel
- Quadrant (-F1, +F2) — Modestes & Fidèles : clients âgés à revenus modestes mais très fidèles
- Quadrant (-F1, -F2) — Modestes & Jeunes : clients jeunes à faibles ressources, peu fidèles

Distribution des catégories : Les clients Electronics (■) se concentrent dans les zones +F1 et +F2, confirmant leur profil aisé et senior. Les clients Luxury (◆) se regroupent en +F1-F2, correspondant aux jeunes riches dépensiers. Les clients Fashion (▲) occupent les zones jeunes (-F2). Les clients Budget (●) sont présents dans les zones à faibles revenus (-F1).

4.3 Étape 5 — Cercle de Corrélation (Carte des Variables)

Le cercle de corrélation représente la projection des 6 variables sur le plan F1×F2. Plus une variable est proche du cercle unité, mieux elle est représentée sur ce plan ($\cos^2$ proche de 1).




Figure 3 — Cercle des corrélations (ACP, plan F1×F2). La flèche épaisse indique un $\cos^2 > 0,60$.

Tableau synthétique — Corrélations variables-axes

Variable	r(F1)	r(F2)	Contrib.F1	Contrib.F2	$\cos^2 F1$	$\cos^2 F2$	Interprétation
Épargne Estimée	0,957	-0,039	33,20 %	0,09 %	0,915	0,002	★★★★ sur F1
Score Crédit	0,857	0,248	26,62 %	3,66 %	0,734	0,061	★★★★ sur F1
Revenu Annuel	0,814	0,191	24,05 %	2,18 %	0,663	0,037	★★★★ sur F1

Années Fidélité	-0,327	0,936	3,87 %	52,24 %	0,107	0,875	★★★ sur F2
Âge	0,170	0,787	1,05 %	36,98 %	0,029	0,620	★★ sur F2
Score Dépenses	-0,556	0,285	11,20 %	4,86 %	0,309	0,081	Partagé F1/F2

F1 — « Axe Richesse Financière » (45,94 %) : Épargne ($r=0,957$, $\cos^2=0,915$), Score Crédit ($r=0,857$) et Revenu ($r=0,814$) sont fortement corrélés à F1 et proches du cercle unité. Ils contribuent à 83,87 % de l'inertie de F1. F1 oppose les clients financièrement aisés (côté +) aux clients modestes (côté -).

F2 — « Axe Fidélité-Maturité » (27,92 %) : Années de Fidélité ($r=0,936$, $\cos^2=0,875$) et Âge ($r=0,787$, $\cos^2=0,620$) dominent F2 avec une contribution cumulée de 89,22 %. F2 oppose les clients âgés et fidèles (côté +) aux clients jeunes et peu fidèles (côté -).

5. ANALYSE DES CORRESPONDANCES MULTIPLES (ACM)

L'ACM est appliquée aux 3 variables qualitatives (Genre, Groupe d'Âge, Catégorie Préférée), soit $Q = 11$ modalités au total. L'inertie totale théorique est $(Q/p)-1 = (11/3)-1 = 2,667$.

5.1 Pré-traitement des variables qualitatives

- 4 valeurs manquantes sur la variable « Groupe d'Âge » (clients n° 34, 66, 92 et 115) traitées par imputation KNN ($k = 5$, pondération par distance) — groupe « 18-25 » attribué aux 4 observations, cohérent avec leur âge réel de 18 ans
- Toutes les modalités ont un effectif suffisant ($n \geq 12$), aucune fusion requise

5.2 Tableau Disjonctif Complet (TDC)

Le TDC est la matrice binaire Z de dimension (200×11) . Chaque ligne contient exactement 3 valeurs « 1 » (une par variable). Somme totale = $200 \times 3 = 600$.

Extrait — 10 premiers clients (sur 200) :

Ind.	S-F	S-H	AG 18-25	AG 26-35	AG 36-50	AG 51-65	AG 65+	CP Budget	CP Elec.	CP Fash.	CP Lux.
1	0	1	1	0	0	0	0	1	0	0	0
2	0	1	1	0	0	0	0	0	0	0	1
3	1	0	1	0	0	0	0	1	0	0	0
4	1	0	1	0	0	0	0	0	0	0	1
5	1	0	0	1	0	0	0	1	0	0	0
6	1	0	1	0	0	0	0	0	0	0	1
7	1	0	0	1	0	0	0	1	0	0	0
8	1	0	1	0	0	0	0	0	0	0	1
9	0	1	0	0	0	1	0	1	0	0	0
10	1	0	0	1	0	0	0	0	0	0	1

S-F=Femme | S-H=Homme | AG=Groupe d'Âge | CP=Catégorie Préférée. Cases bleues = 1 (appartenance à la modalité).

5.3 Tableau de Burt

$B = Z^T Z$, matrice symétrique (11×11) . Diagonale : effectifs de chaque modalité ; hors-diagonale : tableaux de contingence croisés.

	S-F	S-H	AG 18-25	AG 26-35	AG 36-50	AG 51-65	AG 65+	CP Bdg	CP Elec.	CP Fash.	CP Lux.
S-F (112)	112	0	20	37	37	14	4	16	42	22	32
S-H (88)	0	88	18	23	25	14	8	11	36	19	22
AG 18-25 (38)	20	18	38	0	0	0	0	4	3	18	13

AG 26-35 (60)	37	23	0	60	0	0	0	6	0	23	31
AG 36-50 (62)	37	25	0	0	62	0	0	9	43	0	10
AG 51-65 (28)	14	14	0	0	0	28	0	7	21	0	0
AG 65+ (12)	4	8	0	0	0	0	12	1	11	0	0
CP Budget (27)	16	11	4	6	9	7	1	27	0	0	0
CP Electr. (78)	42	36	3	0	43	21	11	0	78	0	0
CP Fashion (41)	22	19	18	23	0	0	0	0	0	41	0
CP Luxury (54)	32	22	13	31	10	0	0	0	0	0	54

- Electronics domine chez les 36-50 ($43/62=69\%$), 51-65 ($21/28=75\%$) et 65+ ($11/12=92\%$)
- Fashion est la catégorie des jeunes : $18/38=47\%$ chez les 18-25, $23/60=38\%$ chez les 26-35
- Luxury est concentré chez les 26-35 ans ($31/60=52\%$)

5.4 Valeurs propres ACM

Axe	Valeur propre	Inertie (%)	Cumulé (%)	Décision
Axe 1	0,344	12,88 %	12,88 %	Retenu
Axe 2	0,298	11,18 %	24,06 %	Retenu
Axe 3	0,241	9,03 %	33,09 %	Retenu

Rappel : en ACM, les faibles % d'inertie sont normaux (inertie totale = 2,667). L'interprétation porte sur la géométrie relative du nuage de modalités.

5.5 Carte Factorielle des Modalités (Plan Axe1 × Axe2)

La carte des modalités représente la position de chaque modalité dans le plan Axe1 × Axe2. La taille des points est proportionnelle à l'effectif de la modalité.




Figure 4 — Carte factorielle des modalités (ACM, Axe 1 x Axe 2). Taille des points proportionnelle à l'effectif. Lignes pointillées : modalités d'une même variable.

Lecture de la carte ACM :

- Axe 1 (22,7 %) — axe d'âge : 65+ et 51-65 (gauche, -Axe1) s'opposent à 18-25 et 26-35 (droite, +Axe1). Les seniors sont à gauche, les jeunes à droite.
- Axe 2 (15,2 %) — axe de catégorie : Fashion et 18-25 (haut, +Axe2) s'opposent à Electronics et Budget (bas, -Axe2).
- Proximity notable : Electronics est très proche des modalités 36-50, 51-65, 65+ — forte association seniors–Electronics.
- Fashion est proche des groupes 18-25 et 26-35, confirme l'association jeunesse–mode.
- Luxury est dans le quadrant +Axe1 (jeunes) mais -Axe2, associé aux 26-35 ans à revenus croissants.
- Les modalités Femme et Homme sont proches du centre, indiquant un effet du sexe modéré sur ces deux axes.

6. CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH)

La CAH est appliquée sur les 6 variables standardisées avec le critère de Ward (minimisation de la perte d'homogénéité intra-classe).

6.1 Choix du nombre de classes

k	Inertie intra-classe	Gain (%)	Observation
2	579,33	—	
3	337,57	41,72 %	Réduction forte
4	274,04	18,82 %	
5	211,15	22,95 % ← Coude	← k retenu
6	171,56	18,72 %	Diminution
7	140,35	18,18 %	Gain marginal

6.2 Profils des 5 classes CAH

Cl.	Âge moy.	Revenu	Sc.Dép.	Épargne	Sc.Crédit	An.Fid.	n	%
0	32,15	44,19	38,02	31,74	726,89	4,65	54	27 %
1	41,69	88,23	17,29	77,83	850,00	4,57	35	17,5 %
2	54,27	53,65	48,98	36,03	774,75	7,39	51	25,5 %
3	25,33	25,10	80,05	11,70	372,38	6,19	21	10,5 %
4	32,69	86,54	82,13	39,20	830,82	6,87	39	19,5 %

Classe 0 — « Jeunes Modestes » (n=54) : Jeunes (32 ans), revenus modérés (44 k\$), score de dépenses contenu (38). Segment intermédiaire en phase de construction financière.

Classe 1 — « Riches Économes » (n=35) : Revenus très élevés (88 k\$), épargne maximale (78 k\$), score de crédit au plafond (850) mais score de dépenses minimal (17). Clients aisés qui n'activent pas leur pouvoir d'achat dans le centre.

Classe 2 — « Seniors Fidèles » (n=51) : La plus âgée (54 ans) avec une fidélité remarquable (7,4 ans). Revenus et épargne modérés. Clientèle de base régulière et prévisible.

Classe 3 — « Jeunes Impulsifs Précaires » (n=21) : Les plus jeunes (25 ans), revenus les plus faibles (25 k\$), score de dépenses maximal (80), score de crédit critique (372). Très dépensiers par rapport à leurs ressources.

Classe 4 — « Jeunes Premium » (n=39) : Segment le plus stratégique : jeunes (33 ans), revenus élevés (87 k\$), score de dépenses maximal (82), excellent crédit (831). Cible idéale pour les offres premium.

7. CLUSTERING PAR K-MEANS

Le K-means est appliqué sur les 6 variables standardisées avec 10 initialisations aléatoires (n_init=10) pour garantir la stabilité du résultat.

7.1 Règle du coude

k	WCSS	Réduction	Observation	Décision
1	1200,00	—	—	—
2	867,04	27,75 %	—	—
3	617,33	28,79 %	—	—
4	446,40	27,66 %	—	—
5	333,24	25,35 %	← Coude	✓ Optimal
6	278,82	16,34 %	Ralentit	—
7	247,43	11,25 %	Marginal	—
8	222,72	9,98 %	Marginal	—
9	198,94	10,68 %	Marginal	—
10	182,04	8,49 %	Marginal	—

7.2 Profils des 5 clusters K-means

Cl.	Âge moy.	Revenu	Sc.Dép.	Épargne	Sc.Crédit	An.Fid.	n	%
0	55,96	49,16	42,88	34,24	759,14	7,27	56	28 %
1	41,26	88,50	16,76	78,33	850,00	4,50	34	17 %
2	26,43	25,86	72,00	13,36	410,50	5,89	28	14 %
3	32,88	86,10	81,53	39,27	831,30	6,85	40	20 %
4	28,05	51,95	42,67	36,28	775,67	4,45	42	21 %

Cluster 0 — « Seniors Electronics » (n=56) : Âge moyen 56 ans, fidèles (7,3 ans), Electronics à 79 %. Clientèle de base régulière.

Cluster 1 — « Riches Économes Tech » (n=34) : Revenus très élevés (89 k\$), épargne max (78 k\$), crédit au plafond (850), dépenses minimales (17). Fort potentiel latent.

Cluster 2 — « Jeunes Précaires Luxe » (n=28) : Très jeunes (26 ans), revenus faibles (26 k\$), crédit bas (411), attirés par Luxury (68 %). Profil aspirationnel.

Cluster 3 — « Jeunes Premium Luxury » (n=40) : ★ Segment le plus stratégique : revenus élevés (86 k\$), dépenses maximal (82), crédit excellent (831), Luxury 87,5 %. Priorité marketing N°1.

Cluster 4 — « Jeunes Femmes Fashion » (n=42) : Féminin (69 %), jeune (28 ans), Fashion à 64 %. Cible idéale pour les campagnes mode et réseaux sociaux.

7.3 Comparaison CAH vs K-means

Segment	CAH (Ward)	K-means	Convergence
Riches Économes	Cl.1 (n=35)	Cl.1 (n=34)	✓ Très forte
Seniors Fidèles	Cl.2 (n=51)	Cl.0 (n=56)	✓ Forte
Jeunes Premium	Cl.4 (n=39)	Cl.3 (n=40)	✓ Très forte
Jeunes Précaires	Cl.3 (n=21)	Cl.2 (n=28)	✓ Forte
Jeunes Fashion	Cl.0 (n=54)	Cl.4 (n=42)	~ Partielle

8. DISCUSSION

L'ensemble des analyses présente une cohérence remarquable. La matrice de corrélation a mis en évidence deux blocs de variables (financier et comportemental-temporel). L'ACP a confirmé cette structure avec les axes F1 « Richesse » et F2 « Fidélité-Maturité », parfaitement lisibles sur les cartes factorielles. L'ACM a révélé des associations fortes entre catégories de consommation et groupes d'âge, illustrées sur la carte des modalités. Les deux méthodes de clustering convergent vers une partition en 5 segments dont les profils sont robustes et interprétables.

Limites

- Le jeu de données ne capture pas la dimension temporelle des achats
- L'ACM produit naturellement des inerties faibles (phénomène connu de la méthode)
- Le K-means est sensible aux outliers (traité ici par standardisation et $n_init=10$)

9. CONCLUSION ET RECOMMANDATIONS

9.1 Synthèse

- ACP : 2 axes majeurs à 73,86 % de variance — F1 « Richesse » (Épargne, Crédit, Revenu) et F2 « Fidélité-Maturité » (Années Fidélité, Âge)
- ACM : Electronics↔Seniors, Fashion↔Jeunes, Luxury↔26-35 ans — lisibles sur la carte des modalités
- CAH et K-means convergent vers 5 segments distincts et interprétables
- Segment stratégique prioritaire : « Jeunes Premium Luxury » (Revenu≈87k\$, Score Dép.≈82, Luxury 87 %)

9.2 Recommandations marketing

Segment	Taille	Recommandations stratégiques
Seniors Electronics	56 (28 %)	Fidélité tech, ateliers pratiques, newsletters spécialisées.
Riches Économes	34 (17 %)	Offres sur-mesure, conseiller dédié, invitations VIP, loisir-investissement.
Jeunes Précaires Luxe	28 (14 %)	Entrée de gamme Luxury, paiement fractionné, parrainage, réseaux sociaux.
Jeunes Premium ★	40 (20 %)	★ PRIORITÉ 1 ★ VIP club, accès anticipé, personnalisation, événements exclusifs.
Jeunes Femmes Fashion	42 (21 %)	Campagnes Instagram/TikTok, influenceuses, éditions limitées, points Fashion.

— Fin du rapport —

ANNEXE — CODE SOURCE COMPLET

Cette annexe regroupe l'intégralité du code utilisé pour produire les analyses statistiques (Python), générer les graphiques (Python/Matplotlib) .

A.1 Code Python — Analyse statistique (ACP, ACM, CAH, K-means)

```
analyse_multidim.py — Chargement, pré-traitement, ACP, ACM, CAH, K-means
# =====
# Mini-Projet N°3 — Analyse des Données Multidimensionnelles
# INSSEDS 2025-2026 | AKPOSSO Didier Martial
# =====

import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans, AgglomerativeClustering
import warnings
warnings.filterwarnings("ignore")

# — 1. Chargement et pré-traitement —————
df = pd.read_csv("Mall Customers.csv")

# Imputation KNN des valeurs manquantes du groupe d'âge (k=5, pondération par distance)
from sklearn.impute import KNNImputer
age_order = {"18-25":1, "26-35":2, "36-50":3, "51-65":4, "65+":5}
age_decode = {1:"18-25", 2:"26-35", 3:"36-50", 4:"51-65", 5:"65+"}
df["Age Group Num"] = df["Age Group"].map(age_order)
knn_cols = ["Age", "Annual Income (k$)", "Spending Score (1-100)", "Age_Group_Num"]
imputer = KNNImputer(n_neighbors=5, weights="distance")
X_imp = imputer.fit_transform(df[knn_cols])
df["Age Group"] = pd.DataFrame(X_imp, columns=knn_cols) ["Age_Group_Num"].round().astype(int).clip(1, 5).map(age_decode)

# Variables quantitatives et qualitatives
quant_vars = ["Age", "Annual Income (k$)", "Spending Score (1-100)",
              "Estimated Savings (k$)", "Credit Score", "Loyalty Years"]
qual_vars = ["Gender", "Age Group", "Preferred Category"]

# — 2. Statistiques descriptives —————
desc = df[quant_vars].describe().round(2)
print(desc)

# — 3. Matrice de corrélation —————
corr = df[quant_vars].corr().round(4)
print(corr)

# — 4. ACP —————
scaler = StandardScaler()
X = scaler.fit_transform(df[quant_vars])

pca = PCA()
coords = pca.fit_transform(X)
eig = pca.explained_variance
inertie = pca.explained_variance_ratio_ * 100
cumul = np.cumsum(inertie)
loadings = pca.components_.T * np.sqrt(eig)
cos2 = loadings ** 2
contribs = (loadings**2 / eig) * 100

# Tableau des valeurs propres
for i in range(6):
    print(f"F{i+1}: λ={eig[i]:.4f} {inertie[i]:.2f}% cumul={cumul[i]:.2f}%")

# Corrélations variables-axes et contributions
for i, v in enumerate(quant_vars):
```

```

    print(f"{v}: r(F1)={loadings[i,0]:.3f}  r(F2)={loadings[i,1]:.3f}"
          f"  contrib_F1={contribs[i,0]:.1f}%  cos2_F1={cos2[i,0]:.3f}")

# — 5. ACM —————
# Tableau Disjonctif Complet
tdc = pd.get_dummies(df[qual_vars], dtype=float)
Z = tdc.values
N = float(Z.sum())

# Vérification : somme = 200 * 3 = 600
print(f"Somme TDC = {int(Z.sum())}  (attendu 600)")

# Tableau de Burt
B = Z.T @ Z
burt = pd.DataFrame(B, index=tdc.columns, columns=tdc.columns)

# Coordonnées ACM par SVD
r = Z.sum(axis=1) # masses lignes
c = Z.sum(axis=0) # masses colonnes
Dr_sqrt_inv = np.diag(1.0 / np.sqrt(r))
Dc_sqrt_inv = np.diag(1.0 / np.sqrt(c))
ri = (Z/N).sum(axis=1, keepdims=True)
cj = (Z/N).sum(axis=0, keepdims=True)
S = Dr_sqrt_inv @ (Z/N - ri * cj) @ Dc_sqrt_inv

U, sv, Vt = np.linalg.svd(S, full_matrices=False)
lambdas = sv ** 2
pct_acm = lambdas / lambdas.sum() * 100

# Coordonnées des modalités (normalisées principales)
mod_coords = Dc_sqrt_inv @ Vt.T * sv[np.newaxis, :]
mod_names = tdc.columns.tolist()

# — 6. CAH (Ward) —————
# Inertie intra-classe pour k = 2 à 8
for k in range(2, 9):
    cah = AgglomerativeClustering(n_clusters=k, linkage="ward")
    labels = cah.fit_predict(X)
    centers = np.array([X[labels==i].mean(0) for i in range(k)])
    intra = sum(np.sum((X[labels==i] - centers[i])**2) for i in range(k))
    print(f"k={k}: inertie={intra:.2f}")

# CAH avec k = 5
cah5 = AgglomerativeClustering(n_clusters=5, linkage="ward")
df["Cluster_CAH"] = cah5.fit_predict(X)
print(df.groupby("Cluster_CAH")[quant_vars].mean().round(2))

# — 7. K-Means —————
# Règle du coude : WCSS pour k = 1 à 10
for k in range(1, 11):
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    km.fit(X)
    print(f"k={k}: WCSS={km.inertia_:.2f}")

# K-means avec k = 5
km5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df["Cluster_KM"] = km5.fit_predict(X)
print(df.groupby("Cluster_KM")[quant_vars].mean().round(2))

# Profils qualitatifs
for c in sorted(df["Cluster_KM"].unique()):
    sub = df[df["Cluster_KM"] == c]
    print(f"Cluster {c} (n={len(sub)}):")
    print("  Gender:", sub["Gender"].value_counts().to_dict())
    print("  Age Group:", sub["Age Group"].value_counts().to_dict())
    print("  Pref Cat:", sub["Preferred Category"].value_counts().to_dict())

```

A.2 Code Python — Génération des graphiques (Matplotlib)

```

# --- Imports ---
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
import matplotlib.ticker as ticker
import numpy as np, pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from PIL import Image

# --- Données ---
df = pd.read_csv("Mall Customers.csv")
df["Age Group"] = df["Age"].apply(lambda a:
    "18-25" if a<=25 else "26-35" if a<=35 else
    "36-50" if a<=50 else "51-65" if a<=65 else "65+")

qv = ["Age", "Annual Income (k$)", "Spending Score (1-100)",
    "Estimated Savings (k$)", "Credit Score", "Loyalty Years"]
vlab = ["Age", "Revenu annuel", "Score dépenses",
    "Épargne estim.", "Score crédit", "Années fidélité"]

X = StandardScaler().fit_transform(df[qv])
pca = PCA(); coords = pca.fit_transform(X)
eig = pca.explained_variance_
pct = pca.explained_variance_ratio_ * 100
cum = np.cumsum(pct)
ldg = pca.components_.T * np.sqrt(eig)

# ---
# FIGURE 1 – Scree plot (diagramme de l'éboulis)
# ---
fig, ax = plt.subplots(figsize=(8, 5))
fig.patch.set_facecolor("FFFFFF")
ax.set_facecolor("#FAFAFA")

dims = np.arange(1, 7)
bars = ax.bar(dims, eig, color="#4472C4", alpha=0.78, width=0.55,
    zorder=3, edgecolor="white", linewidth=0.8)

# Axe secondaire : courbe de l'inertie cumulée
ax2 = ax.twinx()
ax2.plot(dims, cum, color="#ED7D31", marker="o", markersize=6,
    lw=1.8, markerfacecolor="white", markeredgewidth=1.8, zorder=4)
ax2.set_ylim(0, 115)
ax2.set_ylabel("Inertie cumulée (%)", fontsize=10, color="#ED7D31")
ax2.tick_params(axis="y", colors="#ED7D31", labels=9)

# Annotations % sur chaque barre
for i, (bar, p, c) in enumerate(zip(bars, pct, cum)):
    ax.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.04,
        f"{p:.1f}%", ha="center", va="bottom",
        fontsize=8.5, fontweight="bold", color="#2F5496")
    ax2.text(dims[i], c + 2.5, f"{c:.1f}%", ha="center",
        va="bottom", fontsize=7.5, color="#ED7D31")

# Seuil Kaiser
ax.axhline(1, color="#FF0000", lw=1.2, ls="--", alpha=0.7, zorder=2)
ax.text(6.45, 1.04, "λ = 1 (Kaiser)", fontsize=7.5,
    color="#C00000", ha="right", va="bottom")

ax.set_xlabel("Composantes principales", fontsize=10.5)
ax.set_ylabel("Valeur propre (λ)", fontsize=10.5, color="#2F5496")
ax.set_title("Diagramme de l'éboulis – ACP (n=200)", fontsize=11.5)
ax.set_xticks(dims)
ax.set_xticklabels([f"F{i}" for i in dims], fontsize=9.5)
ax.grid(axis="y", alpha=0.25, lw=0.7)
for sp in ["top", "right"]: ax.spines[sp].set_visible(False)
plt.tight_layout()
plt.savefig("fig0_scree.png", dpi=150, bbox_inches="tight")
plt.close()

# ---
# FIGURE 2 – Carte des individus (F1 × F2)
# ---

```

```

cat_colors = {"Electronics": "#2166AC", "Luxury": "#B2182B",
              "Fashion": "#D6604D", "Budget": "#4DAC26"}
cat_markers = {"Electronics": "o", "Luxury": "s", "Fashion": "^", "Budget": "D"}
cats = df["Preferred Category"].values

fig, ax = plt.subplots(figsize=(9, 6.5))
ax.set_facecolor("#F9F9F9")
ax.grid(True, color="#CCCCCC", lw=0.6, alpha=0.6, zorder=0)
ax.axhline(0, color="#888888", lw=0.9, zorder=1)
ax.axvline(0, color="#888888", lw=0.9, zorder=1)

for cat in ["Electronics", "Luxury", "Fashion", "Budget"]:
    idx = cats == cat
    ax.scatter(coords[idx, 0], coords[idx, 1],
              c=cat_colors[cat], marker=cat_markers[cat],
              s=38, alpha=0.72, label=cat,
              edgecolors=cat_colors[cat], linewidths=0.3, zorder=3)

# Annotations quadrant
for txt, x, y in [("Riches & fidèles", 3.8, 2.5),
                 ("Riches & jeunes", 3.8, -2.8),
                 ("Modestes & fidèles", -3.6, 2.5),
                 ("Modestes & jeunes", -3.6, -2.8)]:
    ax.text(x, y, txt, fontsize=7.5, color="#555555",
           style="italic", ha="center", alpha=0.75,
           bbox=dict(boxstyle="round, pad=0.2", facecolor="white",
                   alpha=0.5, edgecolor="none"))

ax.set_xlabel(f"Composante F1 ({pct[0]:.1f} %)", fontsize=10.5)
ax.set_ylabel(f"Composante F2 ({pct[1]:.1f} %)", fontsize=10.5)
ax.set_title(f"Plan factoriel des individus – F1 × F2 ({pct[0]+pct[1]:.1f} % de variance)",
            fontsize=11)
ax.legend(title="Catégorie préférée", fontsize=9, loc="upper left")
for sp in ["top", "right"]: ax.spines[sp].set_visible(False)
plt.tight_layout()
plt.savefig("fig1 individus.png", dpi=150, bbox_inches="tight")
plt.close()

# -----
# FIGURE 3 – Cercle de corrélation
# -----
var_cols = ["#1A5276", "#C0392B", "#1E8449", "#7D3C98", "#B7770D", "#117A65"]

fig, ax = plt.subplots(figsize=(7, 7))
ax.set_facecolor("#FAFAFA")

# Cercles unité et demi-unité
theta = np.linspace(0, 2*np.pi, 400)
ax.plot(np.cos(theta), np.sin(theta), color="#999999", lw=1.1)
ax.plot(0.5*np.cos(theta), 0.5*np.sin(theta), color="#CCCCCC",
        lw=0.6, ls="--")
ax.axhline(0, color="#AAAAAA", lw=0.7)
ax.axvline(0, color="#AAAAAA", lw=0.7)

for i, (lab, col) in enumerate(zip(vlab, var_cols)):
    x1, y1 = ldg[i, 0], ldg[i, 1]
    q = x1**2 + y1**2
    lw = 2.0 if q > 0.6 else 1.2
    ax.annotate("", xy=(x1, y1), xytext=(0, 0),
               arrowprops=dict(arrowstyle="→", color=col,
                               lw=lw, mutation scale=15))
    dx = 0.07 if x1 >= 0 else -0.07
    dy = 0.06 if y1 >= 0 else -0.06
    ax.text(x1+dx, y1+dy, f"{lab}\n(cos²={q:.2f})",
           fontsize=8.5, color=col, fontweight="bold",
           ha="left" if x1>=0 else "right",
           va="bottom" if y1>=0 else "top",
           bbox=dict(boxstyle="round, pad=0.2", facecolor="white",
                   edgecolor=col, alpha=0.82, lw=0.7))

ax.set_xlim(-1.3, 1.3); ax.set_ylim(-1.3, 1.3)
ax.set_aspect("equal")
ax.set_xlabel(f"F1 ({pct[0]:.1f} %)", fontsize=10.5)
ax.set_ylabel(f"F2 ({pct[1]:.1f} %)", fontsize=10.5)
ax.set_title("Cercle des corrélations – Plan F1 × F2", fontsize=11)
for sp in ["top", "right"]: ax.spines[sp].set_visible(False)

```

```

plt.tight_layout()
plt.savefig("fig2_cercle.png", dpi=150, bbox_inches="tight")
plt.close()

# -----
# FIGURE 4 – Carte des modalités ACM
# -----
# Calcul des coordonnées ACM
tdc = pd.get_dummies(df[["Gender", "Age Group", "Preferred Category"]],
                    dtype=float)
Z = tdc.values; N = float(Z.sum())
r_m = Z.sum(axis=1); c_m = Z.sum(axis=0)
Dr_si = np.diag(1/np.sqrt(r_m/N))
Dc_si = np.diag(1/np.sqrt(c_m/N))
ri = (Z/N).sum(axis=1, keepdims=True)
cj = (Z/N).sum(axis=0, keepdims=True)
S_acm = Dr_si @ (Z/N - ri*cj) @ Dc_si

U_a, sv_a, Vt_a = np.linalg.svd(S_acm, full_matrices=False)
mc = (np.diag(1/np.sqrt(c_m/N)) @ Vt_a.T) * sv_a[np.newaxis, :]
pct_acm = sv_a**2 / (sv_a**2).sum() * 100

mn_acm = tdc.columns.tolist()
me_acm = Z.sum(axis=0)

label_map = {"Gender Female": "Femme", "Gender Male": "Homme",
             "Age Group_18-25": "18-25", "Age Group_26-35": "26-35",
             "Age Group_36-50": "36-50", "Age Group_51-65": "51-65",
             "Age Group_65+": "65+", "Preferred Category Budget": "Budget",
             "Preferred Category Electronics": "Electronics",
             "Preferred Category Fashion": "Fashion",
             "Preferred Category_Luxury": "Luxury"}

vg_style = {
    "Gender": {"color": "#C0392B", "marker": "s", "label": "Sexe"},
    "Age Group": {"color": "#1A5276", "marker": "o", "label": "Groupe d'age"},
    "Preferred Category": {"color": "#1E8449", "marker": "^", "label": "Categorie"},
}

fig, ax = plt.subplots(figsize=(8, 6))
ax.set_facecolor("#F9F9F9")
ax.grid(True, color="CCCCCC", lw=0.5, alpha=0.5)
ax.axhline(0, color="#888", lw=0.8); ax.axvline(0, color="#888", lw=0.8)

hdl = []
for vg, sty in vg_style.items():
    pfx = "Preferred" if "Category" in vg else vg
    idxs = [i for i, m in enumerate(mn_acm) if m.startswith(pfx)]
    col = sty["color"]; mrk = sty["marker"]
    ax.scatter(mc[idxs, 0], mc[idxs, 1],
              s=[50 + float(me_acm[i])*0.8 for i in idxs],
              c=col, marker=mrk, alpha=0.82,
              edgecolors="white", lw=0.5, zorder=4)
    for i in idxs:
        x, y = float(mc[i, 0]), float(mc[i, 1])
        lab = label_map.get(mn_acm[i], mn_acm[i])
        ax.annotate(f"{lab} (n={int(me_acm[i])})",
                  xy=(x, y),
                  xytext=(x + (0.02 if x>=0 else -0.02),
                          y + (0.02 if y>=0 else -0.02)),
                  fontsize=8.5, color=col, fontweight="bold",
                  ha="left" if x>=0 else "right",
                  va="bottom" if y>=0 else "top",
                  bbox=dict(boxstyle="round,pad=0.18",
                          fc="white", ec=col, alpha=0.8, lw=0.6))
    # Lignes reliant les modalités d'une même variable
    for a in range(len(idxs)):
        for b in range(a+1, len(idxs)):
            ax.plot([float(mc[idxs[a], 0]), float(mc[idxs[b], 0])],
                    [float(mc[idxs[a], 1]), float(mc[idxs[b], 1])],
                    color=col, lw=0.4, ls="--", alpha=0.25)
    hdl.append(mpatches.Patch(color=col, label=sty["label"]))

ax.set_xlabel(f"Axe 1 ({pct_acm[0]:.1f} %)", fontsize=10.5)
ax.set_ylabel(f"Axe 2 ({pct_acm[1]:.1f} %)", fontsize=10.5)
ax.set_title(f"Plan factoriel des modalités – ACM", fontsize=11)

```

```
ax.legend(handles=hdl, title="Variable", fontsize=9)
for sp in ["top", "right"]: ax.spines[sp].set_visible(False)
plt.tight_layout()
plt.savefig("fig3_acm.png", dpi=130, bbox_inches="tight")
plt.close()

# Conversion RGBA → RGB pour compatibilité docx
for src, dst in [("fig0_screen.png", "fig0_screen_clean.png"),
                ("fig1_individus.png", "fig1_final.png"),
                ("fig2_cercle.png", "fig2_final.png"),
                ("fig3_acm.png", "fig3_final.png")]:
    Image.open(src).convert("RGB").save(dst, "PNG")
    print(f"Converti : {dst}")
```


SOMMAIRE	2
1. INTRODUCTION GÉNÉRALE.....	3
1.1 Problématique.....	3
1.2 Objectifs spécifiques.....	3
2. DONNÉES ET MÉTHODOLOGIE	4
2.1 Présentation du jeu de données	4
2.2 Plan d'analyse.....	4
3. RÉSULTATS	5
3.1 Pré-traitement et Statistiques Descriptives.....	5
3.2 Matrice de Corrélation	6
4. ANALYSE EN COMPOSANTES PRINCIPALES (ACP).....	7
4.1 Étape 3 — Interprétation des inerties	7
4.2 Étape 4 — Carte Factorielle des Individus (Plan F1×F2)	8
4.3 Étape 5 — Cercle de Corrélation (Carte des Variables).....	9
5. ANALYSE DES CORRESPONDANCES MULTIPLES (ACM)	11
5.1 Pré-traitement des variables qualitatives	11
5.2 Tableau Disjonctif Complet (TDC)	11
5.3 Tableau de Burt.....	11
5.4 Valeurs propres ACM	12
5.5 Carte Factorielle des Modalités (Plan Axe1 × Axe2).....	12
6. CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH).....	14
6.1 Choix du nombre de classes	14
6.2 Profils des 5 classes CAH.....	14
7. CLUSTERING PAR K-MEANS.....	15
7.1 Règle du coude	15
7.2 Profils des 5 clusters K-means.....	15
7.3 Comparaison CAH vs K-means.....	16
8. DISCUSSION.....	17
Limites.....	17
9. CONCLUSION ET RECOMMANDATIONS	18
9.1 Synthèse.....	18
9.2 Recommandations marketing.....	18
ANNEXE — CODE SOURCE COMPLET	19
A.1 Code Python — Analyse statistique (ACP, ACM, CAH, K-means)	19
A.2 Code Python — Génération des graphiques (Matplotlib)	20